

Cas Pratique 3 : Traitement de données de mesure des vagues

Description du problème :

Nous avons en notre possession mes mesures de vagues issues s'un capteur déployé en mer pendant une période donnée. La fréquence d'échantillonnage est de 8 Hertz.

Objectif :

Démontrer la compréhension du workflow du traitement de données de mesure des vagues dans le cadre des missions futures dès la prise de poste.

1. Exploration des données

1.1. Ajustement du format de temps

Au regard du format de temps, on remarque qu'il est au format de **datenum** qui affecte à chaque date un numéro. Il faut donc au préalable les convertir au format **datetime** sachant que python utilise le format Unix (la date de début est le 01-01-1970).

La méthode utilisée dans le cadre de cette étude est l'utilisation de l'offset avec les dates MATLAB et la conversion des **datenum** obtenue à l'aide de la bibliothèque **Pandas**. Le script python est le suivant :

```
pd.to_datetime(Burst_Time - 719529, unit='D')
```

1.2. Exploration des séries temporelles brutes d'élévation

La figure 1 présente l'évolution de l'élévation du niveau d'eau sur la période de mesure. Sur ce graphe, nous observons tout d'abord fait que le signal au début et à la fin de la série présente un décalage du reste de la série. Ce décalage correspond très probablement à la mise à l'eau et au retrait du capteur de l'eau. Il conviendrait de ne pas considérer ces instants lors de l'analyse des données.




Figure 1 : Série temporelle brute

Par ailleurs, nous constatons que le signal n'est pas centré à l'origine. Nous devons donc le centrer avant toute manipulation des données.

2. Prétraitement des données et ajustement de la qualité des données

2.1. Regrouper le temps et les mesures de l'élévation dans un dataframe

Pour faciliter la manipulation des données, j'ai regroupé les élévations et les dates dans un dataframe. Le but est d'avoir un tableau facile à utiliser. Ledit dataframe a été nommé `df`

2.2. Centrage du signal

La méthode utilisée pour centrer le signal est la soustraction de la moyenne.

```
df['eta_cent'] = df['eta'] - np.mean(df['eta'])
```

2.3. Vérification des trous dans la série

2.3.1. Évaluation des élévations

La méthode utilisée pour vérifier la présence des trous dans les valeurs de l'élévation était celle de compter les NAN (Not a Number) de la série à l'aide de la commande :

```
df['eta_cent'].isna().sum()
```

Le résultat était 0. Nous en déduisons donc qu'il n'y a aucun trou.

2.3.2. Évaluation de la constance du pas de temps

Pour évaluer si le pas de temps est constant tout au long de la série, nous évaluons sa variation tout au long de la période de mesure. La fonction utilisée sous python est la suivante :

```
dt = np.diff(df['temps'])
```

La visualisation de cette variation de pas de temps est illustrée par la figure 2 ci-dessous.




Figure 2 : Différence des pas de temps consécutifs

Nous remarquons au regard de cette illustration que le pas de temps n'est pas constant. Par conséquent, il est nécessaire de créer une nouvelle grille temporelle à pas constant qui sera la base de nos futures opérations. (Pour les différentes étapes, voir code python)

2.4. Gestion des valeurs aberrantes

Sont considérées comme aberrantes deux types de valeurs : les valeurs dépassant un seuil physique raisonnable et des variations beaucoup trop importantes et qui ne sont pas logiques physiquement. Dans le cadre de cette étude, le premier cas est géré en affectant des **Nan**.

Pour des variations aberrantes, la première phase de la méthode consiste à supprimer les vitesses (variations) considérées comme très élevées lorsqu'elles dépassent un seuil fixé. Une interpolation linéaire est ensuite effectuée pour corriger ces valeurs.

2.5. Interpolation des valeurs pour les pas de temps créés

Étant donné que nous avons reconstitué une grille temporelle, il y a des trous dans les valeurs d'élévation pour les différents pas de temps inexistant dans la série de base. Pour les compléter, la méthode d'une interpolation par spline d'ordre 2 a été utilisée.

2.6. Filtrage du bruit et séparation des phénomènes physiques

Ces différents éléments sont repérés à partir de leurs différentes fréquences : le bruit a été considéré comme un phénomène à très haute fréquence (1 Hertz), la marée à basse fréquence (12h) et les vagues dans la bande passante entre la marée et le bruit.

Le filtre utilisé est celui de Butterworth. Il a été choisi à cause de sa facilité de mise en œuvre, son efficacité dans la réduction du bruit et le fait qu'il conserve la forme du signal. Par la suite, ce filtre a été appliqué de façon à parcourir le signal dans les deux sens (avant-arrière et arrière-avant) dans le but d'éviter un déphasage du signal. La figure 3 illustre une superposition des différents résultats.




Figure 3 : Séries temporelles superposées

3. Exploitation des données

3.1. Analyse Spectrale

Les précédentes étapes suivies jusqu'ici nous garantissent un caractère continu des données.

Nous pouvons donc réaliser une analyse spectrale. La méthode utilisée ici est le calcul de la densité spectrale de puissance par la méthode de Welch avec des segments de 30 min. Par la suite, les relations de la distribution de Rayleigh ont été utilisées pour avoir la hauteur significative ainsi que la période pic.

La figure 4 ci-dessous nous présente l'évolution de la hauteur significative sur la série de mesure. Les deux lignes rouges verticales ont été ajoutées pour indiquer l'intervalle de temps à considérer (Ne pas considérer les instants de mise à l'eau et du retrait à l'eau du capteur.)




Figure 4 : Évolution du H_s sur chaque heure